

ReL4：高性能异步微内核设计与实现

廖东海¹, 陆慧梅¹, 陈伟豪², 赵方亮³, 向勇³

¹ (北京理工大学 计算机学院 北京市 100081)

² (北京航空航天大学 计算机学院 北京市 100191)

³ (清华大学 计算机科学与技术系 北京市 100084)

E-mail: xiangyong@tsinghua.edu.cn

摘要: 微内核在安全性、稳定性和模块化方面相比于宏内核有着极大的优势。然而以 seL4 为代表的现代微内核在设计上存在三点缺陷:其一,在支持同步进程间通信(IPC)的情况下冗余地支持了异步通知,这违背了微内核的最小化原则;其二,通知机制依赖内核的转发;其三,系统调用和同步 IPC 需要频繁地进出内核,后两点导致了特权级切换成为系统的性能瓶颈。本文旨在设计一款基于用户态中断的高性能异步微内核 ReL4,来解决上述问题,其主要特征有:1)在保证功能完备性的前提下,移除同步 IPC,精简微内核机制;2)基于用户态中断,设计了无需内核转发的 U-notification,减少了特权级切换的开销;3)在 U-notification 基础上,借助异步编程机制,设计了无需陷入内核的异步系统调用和异步 IPC 框架,在简化用户态编程模型的同时,进一步减少特权级的切换次数。经测试验证,ReL4 将 IPC 性能最高提升了 3x,在 IPC 频繁的系统(如网络服务器)中将吞吐量提升了 1x,证明了 ReL4 在高并发系统上有着良好的性能。

关键词: 微内核; 异步; 进程间通信; 用户态中断

中图分类号: TP

文献标识码: A

ReL4: Design and Implementation of High-performance Asynchronous Microkernel

LIAO Dong-hai¹, LU Hui-mei¹, CHEN Wei-hao², ZHAO Fang-liang³, XIANG Yong³

¹ (School of Computer Science & Technology, Beijing Institute of Technology, Beijing 100081, China)

² (School of Computer Science and Engineering, Beihang University, Beijing 100191, China)

³ (Department of Computer Science and Technology, Tsinghua University, Beijing 100084, China)

Abstract: Microkernels have significant advantages over monolithic kernels in terms of security, stability, and modularity. However, modern microkernels represented by seL4 have three design flaws: First, while supporting synchronous inter-process communication (IPC), they redundantly support asynchronous notifications, which violates the minimization principle of microkernels. Second, the notification mechanism relies on kernel forwarding. Third, system calls and synchronous IPC require frequent entry and exit from the kernel, and the latter two points lead to privilege-level switching becoming a performance bottleneck of the system. This paper aims to design a high-performance asynchronous microkernel ReL4 based on user-mode interrupts to address the above-mentioned issues. Its main features are as follows: 1) On the premise of ensuring functional completeness, remove synchronous IPC and streamline the microkernel mechanism. 2) Based on user-mode interrupts, design U-notification that does not require kernel forwarding, reducing the overhead of privilege-level switching. 3) On the basis of U-notification, with the help of asynchronous programming mechanisms, design an asynchronous system call and asynchronous IPC framework that does not need to trap into the kernel. This not only improves the concurrency degree in the user mode but also further reduces the number of privilege-level switches. Through testing and verification, ReL4 has improved the IPC performance by up to 3 times, and in systems with frequent IPC (such as network servers), the throughput has been doubled, proving that ReL4 has good performance on highly concurrent systems.

Key words: microkernel; asynchronous; inter-process communication; user-mode interrupt

收稿日期: 2025-01-28 基金项目: This work was supported by the National Key R&D Program of China(2023YFB4503701) 作者简介: 廖东海, 男, 1999-, 硕士研究生, 目前学历, 技术职称等, 研究方向为微内核、异步编程方向; 陆慧梅, 女, 博士, 副教授, 研究方向为计算机网络体系、操作系统设计与实现; 陈伟豪, 男, 硕士研究生, 研究方向为操作系统内核; 赵方亮, 男, 硕士研究生, 研究方向为操作系统内核, 异步编程; 向勇, 男, 副研究员, 研究方向为操作系统内核分析、车载自组网(6号宋体)

0 引言

微内核采用模块化设计,更易于维护和升级,提高了系统的可靠性、灵活性和安全性,具有更强的可移植性和定制能力,核心功能的分离减少了系统受攻击的风险,相比宏内核具有显著优势^[1]。然而,自从微内核提出以来,最大的性能瓶颈就是进程间通信(IPC)^[2],30年前 Liedtke 提出的 L4^[3]重新设计了微内核系统,通过组合系统调用、快速路径、消息寄存器等优化手段,从硬件层到软件层对 IPC 进行了系统优化,证明了微内核的 IPC 也可以很快,之后以 seL4^[4]为代表的现代微内核的 IPC 框架也基本延续了 L4 的设计理念,以同步 IPC 作为主要的通信方式,而为了更好地利用硬件资源,现代微内核大多引入异步的通知机制来简化多线程程序设计,提升多核的利用率,这违反了微内核的最小化设计原则,增加了内核的复杂性。

随着软件复杂性的提升,系统级软件如数据库管理系统、网络服务器等,要求系统能够快速处理大量系统调用和 IPC^[5],而微内核将操作系统的大部分服务(如网络协议栈、文件系统等)移到用户态,从而使得 IPC 数量和频率激增,特权级切换成为性能瓶颈。此外,新出现的硬件漏洞如 Meltdown^[6]和 Spectre^[7]漏洞促使内核使用 KPTI^[8]补丁来分离用户程序和内核的页表,进一步增加了陷入内核的开销。最后,现代微内核的外设驱动往往存在于用户态,外设中断被转化为异步通知,需要用户态驱动主动陷入内核来进行接收,这在一定程度上成为了外设驱动的性能瓶颈^[9]。

本文提出 ReL4,一个用 Rust 编写的高性能异步微内核,它将同步 IPC 从内核中移除,基于用户态中断技术设计了 U-notification,在兼容 capability 机制的基础上改造微内核的通知机制,并利用改造后的 U-notification 和异步化编程设计和实现了一套绕过内核的异步 IPC 异步系统调用框架。

1 背景与相关工作

1.1 微内核 IPC 的发展现状

现代微内核的大部分 IPC 优化始于 Liedtke 提出的 L4,由于之前的微内核 IPC 存在性能瓶颈,L4 从硬件优化、系统架构、软件接口的各个方面对 IPC 进行了重新设计。其中的优化角度可以简单划分为内核路径优化和上下文切换优化。

对于内核路径优化,L4 通过物理消息寄存器来传递短消息,从而避免了内存拷贝,然而随着访存速度的加快,消息寄存器的零拷贝优化带来的收益逐渐减弱,使用物理寄存器导致的平台依赖和编译器优化失效反而限制了系统的性能^[10],因此物理的消息寄存器逐渐被现代微内核以虚拟消息寄存器代替;此外,L4 使用临时映射的形式来进行长消息的传递,避免多余的内存拷贝,但却在内核中引入了缺页异常的可能性,增加了内核行为的复杂性^[10],现代微内核一般放弃了这个优化;针对常用且普遍的 IPC 场景,L4 设计

了专门的快速路径,避免了复杂繁琐的参数解析和任务调度,然而快速路径对消息长度、任务优先级有着严格的限制,也无法对多 CPU 核心进行支持。

对于特权级的切换优化,L4 使用的物理消息寄存器在一定程度上减少了上下文切换的开销,但其副作用超过了优化收益导致其被虚拟消息寄存器代替^[10];同时 L4 敏锐地观察到大部分 IPC 通信遵循 C/S 模型,因此通过组合系统调用的形式,将 Send + Reply 组合为 Call,将 Reply + Recv 组合成 ReplyRecv,从而减少了特权级切换的频率,该优化至今作为现代微内核的重要优化手段,但仍然无法避免特权级的切换;此外,L4 通过通过 ASID 机制,在快表项中维护地址空间标识符,减少快表冲刷的频率,缓解了快表污染的问题,然而依然无法避免特权级切换带来的快表污染和缓存失效。

除此之外,L4 仅支持同步 IPC,对于多核架构,同步 IPC 会导致服务调用被顺序执行,导致资源浪费。其次,同步 IPC 强制用户态以多线程的形式处理并发请求,导致了线程同步的复杂性。现代微内核在内核中引入异步通知机制,简化并发编程模型,却使得内核功能冗余,违反了内核最小化原则。

总而言之,现代微内核在单核环境下的 IPC 内核路径上的优化已经较为完善,在最理想的情况下仅需要两次特权级切换,然而对多核环境下,由于需要核间中断,IPC 无法进入快速路径,导致多核下的 IPC 内核路径依旧冗长。而现代微内核在特权级切换的优化方面仍然停留缓解的层面上,导致特权级切换会成为 IPC 的性能瓶颈。

1.2 特权级切换

特权级的开销主要分为两部分,一部分是直接开销,包括了保存上下文带来的额外指令开销,另一部分是间接开销,地址空间切换所引起的缓存污染会导致 CPU 执行效率降低。表 1 展示了在 FPGA 上部署的 seL4 一次 Call IPC 操作所带来的开销占比,大部分的时间开销都存在于地址空间切换上。其次是上下文的切换和 fast-path 检查,如果 fast-path 检查失败,将会进入 slow-path 进行更加冗长的解码流程,进一步导致 IPC 性能的下降。

表 1 seL4 一次 IPC 中各操作的开销占比

Table 1 The proportion of operational costs in each individual Inter-Process Communication (IPC) within the seL4

microkernel	
操作	占比
保存和恢复上下文	14.5%
地址空间切换	59.4%
fast-path 检查	20.1%
消息拷贝	1.5%
其他	4.5%

本文聚焦现代微内核架构设计中的特权级切换开销,旨

在设计一种新型的 IPC 架构，减少甚至消除 IPC 和系统调用中的特权级切换，先前已经有大量的工作从软硬件的角度致力于减少特权级切换开销。

从硬件出发的角度，大多数工作通过设计特殊的硬件或者特殊的指令来绕过内核实现 IPC。如 SkyBridge^[11]允许进程在 IPC 中直接切换到目标进程的虚拟地址空间并调用目标函数，它通过精心设计一个 Root Kernel 提供虚拟化的功能，通过 VMFUNC 地址空间的直接切换，并通过其他一系列软件手段来保证安全性，但这种方案仅适用于虚拟化环境中。XPC^[12]则直接使用硬件来提供一个无需经过内核的同步功能调用，并提供一种新的空间映射机制用于调用者与被调用者之间的零拷贝消息传递，然而该方案没有相应的硬件标准，也没有一款通用的处理器对其进行支持。这些方法都基于特殊的环境或者没有标准化的硬件来实现，适用范围有限。

从软件出发的角度，相关工作主要分为两类：第一类方法通过将用户态和内核态的功能扁平化来减少内核与用户态的切换开销，如 unikernel^[13, 14, 15]将所有用户态代码都映射到内核态执行，Userspace Bypass^[16]通过动态二进制分析将两个系统调用之间的用户态代码移入内核态执行，从而减少陷入内核的次数，kernel bypass^[17, 18]则通过将硬件驱动（传统内核的功能）移入用户态，从而减少上下文的切换。这些方法要么需要特殊的硬件支持，要么难以与微内核的设计理念兼容。第二类方法则是允许用户空间对多个系统调用请求排队，并通过一次提交将他们注册给内核，如 FlexSC^[19]通过在用户态设计一个用户态线程的运行，将用户态线程发起的系统调用自动收集，然后陷入内核态进行批量执行。该方法虽然可以有效的减少陷入内核的次数，但如何设置提交的时机难以把握，过短的提交间隔将导致切换次数增加，过长的提交间隔则会导致 CPU 空转。

虽然现有工作难以广泛且有效地应用到微内核中，但他们的思路值得借鉴，他们的缺陷驱使研究者去寻求更好的方案。在硬件方面，一种新型的硬件技术方案——用户态中断^[20, 21]逐渐被各个硬件平台（x86，RISC-V）采纳，它通过在 CPU 中新增中断代理机制和用户态中断的状态寄存器，当中断代理机制检测到状态寄存器发生变化时，会将中断以硬件转发的形式传递给用户态程序，从而绕过内核。该硬件方案已经在 Sapphire Rapids x86 处理器上和 RISC-V 的 N 扩展中有了一定的支持，适用范围更加广泛。而在软件方面，异步被广泛用于请求合并和开销均摊，传统类 Unix 系统提供的类似 select IO 多路复用接口相对简陋，迫使用户态代码采用事件分发的编程范式来处理异步事件，代码相对复杂，可读性较弱。而新兴的 Rust^[22, 23]语言对异步有着良好的支持，其零成本抽象的设计也让它作为系统编程语言有着强大的竞争力。使用 Rust 进行内核和用户态基础库的开发，可以更好地对异步接口进行抽象，改善接口的易用性和代码的可读性。

表 2 IPC 优化的相关工作

Table 1 Related work on the optimization on IPC

优化方法	详细分类	实例	缺点
减少内核路径	临时地址映射	[3]	上下文切换开
	快速路径	[3, 4, 24, 25,	销已经成为性
	消息寄存器	26]	能瓶颈。
减少上下文切 换开销	消息寄存器	[3, 4, 24, 25,	无法从根本上
	组合系统调用	26]	消除切换开
	ASID 机制	[4]	销。
硬件优化	同一地址空间	[13, 14, 15, 16,	与微内核设计
	批量系统调用	17, 18]	理念相悖。
		[12]	
	虚拟化指令	[11]	仅适用于虚拟
	直接硬件辅助	[12]	化环境。
		[20, 21]	没有通用硬件
			的支持。

2 系统设计

为了精简内核，本文提出 ReL4，一个精简的高性能异步微内核。ReL4 将 IPC 从微内核中移除，内核仅支持通知机制，由用户态实现异步 IPC 和异步系统调用，所有的数据传递都通过共享缓冲区实现，由通知机制进行同步。在整个过程中，有两个挑战急需解决：

1. 性能问题：通知机制作为同步手段可能造成大量的特权级切换，成为性能瓶颈。
2. 易用性问题：异步 IPC 和异步系统调用需要额外的通知机制和互斥手段保证其正确性，用户态的程序设计将变得更加复杂。

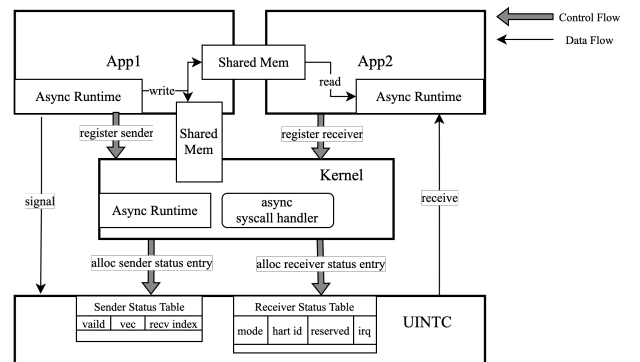


图 1 系统框架图

Fig.1 System Framework Diagram

如图 1 所示，针对以上两个问题，本文基于用户态中断控制器（UINTC），在内核态重新设计了异步通知机制，内核仅负责硬件资源的分配与释放，通知的发送与接收由硬件

完成, 无需特权级切换。针对易用性问题, 本文在用户态设计了异步运行时, 提供了共享缓冲区与协程接口来简化用户态编程模型。

2.1 通知机制

ReL4 将整个系统中通知机制按照收发双方的特权级进行分类: 1) 用户态通知用户态; 2) 内核态通知用户态; 3) 用户态通知内核态; 4) 内核态通知内核态

本文希望借助用户态中断并辅助软件设计, 尽量避免通知过程中的特权级切换。对于 1) 和 2) 而言, ReL4 借助用户态中断, 重新设计了 seL4 的通知机制, 避免了特权级切换, 对于 3), ReL4 通过系统调用的形式通知内核, 并通过自适应轮询机制减少通知的次数, 对于 4), 不存在特权级的切换, 仅通过核间中断就可以实现内核态之间的通知。因此本文将着重介绍基于用户态中断的通知机制 (U-notification), 以及用于减少通知次数的自适应混合轮询机制。

2.1.1 U-notification

如图 2 所示, 用户态中断使得控制流和数据流相互分离。ReL4 在的 notification 内核对象中维护了对应的硬件资源索引, 控制流主要由用户态向内核进行注册, 申请硬件资源, 数据流则通过特殊的用户态指令访问用户态中断控制器, 从而在通信过程中避免了特权级的切换。

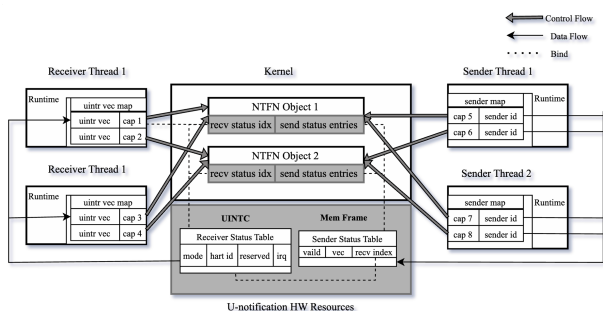


图 2 U-notification 架构图

Fig.2 U-notification Architecture Diagram

控制流主要分为发送方的注册和接收方的注册。接收方在用户态通过 `Untyped_Retype` 申请一个 Notification 对象之后, 调用 `TCB_Bind` 接口进行硬件资源绑定, 运行时进一步调用 `UintrRegisterReceiver` 系统调用, 将运行时中定义的用户态中断向量表注册到 TCB 中, 申请 UINTC 的接收状态表项, 并绑定到 Notification 对象及其对应的线程上。发送方通过 Capability 派生的形式 (直接构造发送方的 Capability 空间, 或通过内核转发的形式获取 Capability) 获取指向 Notification 对象的 Capability, 第一次调用 `Send` 操作时, 运行时判断 Cap 是否有对应的 Sender ID, 如果没有, 则调用 `UintrRegisterSender` 系统调用进行发送端注册, 并填充对应的 SenderID。相关资源的回收则通过已有的 `revoke` 或 `delete` 系统调用注销内核对象。

数据流由硬件直接传递, 无需通过内核。发送端在注册完成之后, 可以直接调用 `uipi_send` 指令, 指令根据 Sender Status Table Entry 中的索引设置中断控制器中的寄存器。如果接收端本身在 CPU 核心上运行, 会立刻被中断并跳转到

注册的中断向量表, 否则会等到被内核重新调度时再处理数据。

2.1.2 自适应混合轮询

虽然用户态中断的开销小于特权级切换, 但仍然对程序局部性和内存局部性不够友好, 且用户态通知内核态仍然要进行特权级的切换, 而轮询虽然可以避免中断式通知, 但却会导致 CPU 资源的浪费, 因此 ReL4 在共享缓冲区中维护通知处理程序的就绪状态标识。当通知频率足够高或处理程序负载足够大, 以至于上一个通知还未被处理完成, 下一个通知就即将发起, 处理程序会始终处于运行状态, 此时无需发送额外的通知, 其工作方式等价于轮询模式。当通知频率较低时, 处理程序在大部分时间处于阻塞状态, 节省 CPU 资源, 工作方式等价于中断模式。

2.2 异步运行时

由于内核不再支持同步 IPC, 为了提升用户态的易用性, ReL4 在用户态设计了异步运行时, 它提供了如下功能, 使得用户态程序设计变得更加简单和高效:

1. 共享缓冲区: 用于跨进程的零拷贝数据传递。
2. 协程与调度器: 提升用户态的并发度, 减少用户态中断和特权级切换次数, 并为不同负载的任务提供可定制性调度策略。
3. API 兼容层: 提供与 seL4 相同的通知机制、异步系统调用和异步 IPC 的用户态接口, 提升系统易用性。

2.2.1 共享缓冲区

由于 U-notification 只能传递通知信号, 因此 ReL4 依然需要共享缓冲区来作为 IPC 数据传递的主要形式。以 IPC 中最常见的 Call 为例, 客户端需要将请求数据准备好并写入共享缓冲区中, 而服务端将在某个时刻从共享缓冲区中读取请求, 处理后将响应写回共享缓冲区, 而客户端也将在之后的某一时刻从共享缓冲区中读取响应并进行相应处理。这个流程中有几个挑战需要明确: 1) 请求和响应的格式和长度如何设计才能使得缓冲区访问效率更高。2) 在共享缓冲区中如何组织请求和响应的存取形式, 才能在数据安全读写的前提下保证性能。3) 客户端和服务端如何选择合适的时机来接收数据。




图 3 共享缓冲区结构图

Fig.3 Structure Diagram of Shared Buffer

如图 3 所示, 一个 IPC 消息 (请求或响应) 被定义为 IPCItem, 它是 IPC 传递消息的基本单元, 为了减少消息读写以及编解码的成本, ReL4 采用定长的消息字段。每个 IPCItem 的长度被定义为缓存行的整数倍并对齐, 消息中的前四个字节用于存储提交该消息的协程 id, 方便后续通过响应进行唤醒。msg info 用于存储消息的元数据, 包含了消

息类型、长度等。`extend msg` 将被具体的应用程序根据不同的用户进行定义。

由于共享缓冲区会被一个以上的线程同时访问，因此需要设计同步互斥操作来保证数据的读写安全。同时共享缓冲区的访问极为频繁，需要尽可能避免数据竞争来保证读写性能。ReL4 将请求和响应放到不同的环形缓冲区中，同时不同的发送方和接收方使用不同的环形缓冲区以保证单生产者单消费者的约束，消除过多的数据竞争，最后，ReL4 使用无锁的方式^[27]进一步提升环形缓冲区的读写性能。

最后，为了支持 2.1.2 中所提到的自适应轮询机制，ReL4 还在共享缓冲区维护了对端处理程序的就绪状态标识 `co_status`。

2.2.2 协程与调度器

传统微内核中的同步 IPC 会导致发送端线程阻塞，从而造成一些没有依赖的 IPC 被迫以顺序的形式执行，或者强制要求多线程来实现并发。而 ReL4 中的异步运行时将协程作为任务的执行单元，以提升用户态并发度，ReL4 中的协程主要分为 worker 协程和 dispatcher 协程，用户态的 IPC 任务都将被封装到 worker 协程，由运行时内的调度器进行调度。Dispatcher 是一个常驻协程，用于读取共享缓冲区中的数据，并根据数据类型分发到具体的处理程序中。

协程通过调度器调度执行。从调度器的角度来看，不同进程的调度器相互独立，每个进程中的 worker 协程和 dispatcher 协程，这两类协程存在着一定的依赖关系。以 IPC 场景下的客户端为例，worker 协程用于发起 IPC 请求，dispatcher 协程则是处理响应。从高吞吐率的角度来讲，自然是希望更快的处理 worker 协程，而从低延迟的角度来讲则是希望优先调度 dispatcher 协程，高吞吐和低延迟的特性由上层业务决定，框架层只根据业务配置进行支持。此外，不同的 worker 协程也需要有轻重缓急之分，以便更有效率地利用 CPU 资源。

基于上述原因，ReL4 在调度器中维护了一个优先级队列，每个协程都被设有相应的优先级，调度器在内部维护了一个优先级位图和若干任务队列，调度器将根据优先级位图选出最高的优先级，找到对应的任务队列并以先进先出的形式选出任务来运行。用户态程序根据业务特点设置相关的优先级，以达到性能调优的目的。

2.2.3 API 兼容层

为了使异步系统调用和异步 IPC 能够与同步系统调用的接口保持一致，异步运行时提供了异步系统调用和 IPC 的 hook 库，用户态的请求将会被 hook 库接管，hook 库根据不同的调用类型，来自动选择是否转化为异步系统调用或 IPC。需要注意的是，无法转化为异步系统调用的主要有以下两类：

- 1) 由于异步系统调用依赖于异步运行时，因此与异步运行时初始化相关的系统调用无法被异步化。

- 2) 对于实时性要求较高的系统调用无法进行异步化，如 `get_clock()`。

而为了尽可能兼容 seL4 中的 capability 机制，运行时库中还维护了 notification cap 与用户态中断相关资源的映射：

- 1) sender map: 由于基于用户态中断的 notification 以及异步 IPC 都无需通过内核，因此运行时需要维护 capability 与 sender id 以及共享缓冲区的映射关系。
- 2) uintr vec map: 用户态中断通过中断向量区分发送端，而 seL4 通过 capability 区分发送端，为了兼容多发送端，运行时需要维护相关的映射关系。

3 系统实现

为了简洁高效地实现异步微内核的原型系统，本项目使用 Rust 语言在 RISC-V 平台上实现了一个兼容 seL4 的微内核 ReL4，目前已经支持 SMP 架构和 fast-path 优化。在兼容 seL4 原始功能的基础（包括 SMP 和 fast-path 优化）上，ReL4 实现了 U-notification 以及异步 IPC 和异步系统调用。在实现过程中对内核接口更改和使用的一些重要细节将在本章描述。

3.1 新增系统调用

表 3 新增系统调用

Table 3 New system calls

syscall	参数	描述
UintrRegisterSender	ntfn_cap	注册通知发送端
UintrRegisterReceiver	ntfn_cap	注册通知接收端
UintrRegisterAsyncSyscall	ntfn_cap, buffer_cap	注册异步系统调用处理协程
UintrWakeSyscallHandler	\	唤醒系统调用处理协程

如表 3 所示，为了支持内核对 U-notification 的资源管理，ReL4 新增了系统调用：UintrRegisterSender 和 UintrRegisterReceiver 用于申请相关的硬件资源。此外，为了支持异步系统调用，共享缓冲区也需要通过系统调用 (UintrRegisterAsyncSyscall) 注册给内核，同时内核提供一个用于唤醒系统调用处理协程的系统调用 UintrWakeSyscallHandler。这些系统调用均由异步运行时代理调用，用户程序无需感知。

3.2 异步 IPC

异步 IPC 作为 ReL4 中的主要的 IPC 方式，其实现依赖于异步运行时和 U-notification。以 IPC 中最常见的 Call 为例，如图 4 所示，客户端进程和服务端进程在双方建立连接时都会注册一个 dispatcher 协程用于不断从共享缓冲区中读取数据并进行处理。运行时库分别对服务端和客户端的 dispatcher 协程提供了两个默认实现，对于特殊的需求，用户程序可以通过运行时接口自定义 dispatcher 协程的行为。服务端 dispatcher 协程读取请求并处理后将响应写入环形缓冲区，并根据标志位判断是否发送 U-notification，没有

请求时阻塞自己并切换到其他 worker 协程。客户端的 dispatcher 协程读取响应并唤醒响应的协程，没有响应时阻塞切换。

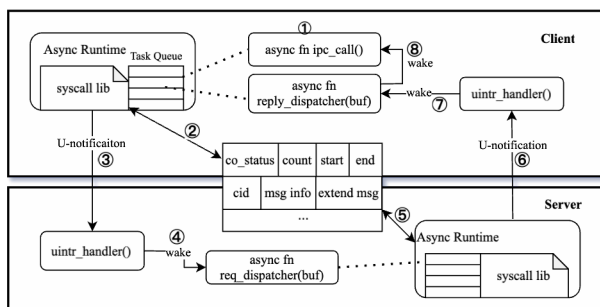


图4 异步IPC流程图

Fig.4 Asynchronous IPC Flowchart

Call 的主要流程分为以下几个阶段:

1) 客户端发起请求: 用户态程序将以 worker 协程的形式发起 IPC 请求, 异步运行时首先会根据请求的数据和协程的协程号生成 IPCItem 并写入请求的环形缓冲区中并将当前协程阻塞, 然后检查缓冲区的 req_co_status 标志位, 如果对方的 dispatcher 协程已经就绪, 那客户端无需通知对方进程, 对方进程的异步运行时会在某个时刻调度到 dispatcher 协程并处理请求。如果对方的 dispatcher 协程处于阻塞状态, 则异步运行时会将 req_co_status 标志位置位, 并发送 U-notification 通知对方进程唤醒 dispatcher 协程并重启调度。

2) 服务端处理请求并写回响应: 服务端的 dispatcher 协程会在合适的时机读取出请求并进行解码和处理, 然后根据处理结果构造响应的 IPCItem 并写入响应的环形缓冲区中, 检查缓冲区中的 reply_co_status 标志位, 如果客户端的响应 dispatcher 协程就绪, 则无需发起通知, 否则需要发起 U-notification 通知客户端进程唤醒 dispatcher 协程并重启调度。如果缓冲区内容为空, dispatcher 协程会将 req_co_status 标志位置空, 并将自己阻塞。

3) 客户端处理响应: 客户端的 dispatcher 协程会在合适的时机读取响应并唤醒之前阻塞的协程, 然后重启调度。

3.3 异步系统调用

从广义的角度来看, 异步系统调用是一类特殊的异步 IPC, 其接收方为内核。因此 ReL4 在内核中提供了一套相似的异步运行时以支持异步系统调用。异步系统调用与异步 IPC 的主要不同之处有两点: 1) 由于接收端是内核, 发送端无法使用 U-notification 去通知内核。2) 异步 IPC 中进程的异步调度器就是进程的执行主体, 无需考虑异步任务的执行时机, 而内核除了异步系统调用请求需要调度器执行, 本身就有如中断、异常、任务调度等其他任务需要被执行。

对于第一点, ReL4 新增一个系统调用去用于唤醒相关的内核协程即可。而对于第二点, 一个很简单的思路是每次时钟中断到来时去执行异步系统调用, 然而这可能会导致空闲的 CPU 核心无法及时触发时钟中断而空转, 因此, 在不

破坏原本的线程优先级调度前提下, ReL4 使用核间中断来抢占空闲 CPU 核心或正在运行低优先级线程的 CPU 核心, 更好地利用空闲 CPU 资源, 减少响应时延。

为了避免破坏微内核中原来的优先级调度机制, ReL4 在内核中对每个 CPU 核心维护了相应的执行优先级 (exec_prio), 执行优先级区别于上文提到的运行时协程优先级, 是由内核调度器维护的线程优先级。内核中的任务主要分为三类: 1) idle_thread: 空闲 CPU 核心执行 idle 线程, 此时 CPU 核心的执行优先级为 256, 属于最低的执行优先级。2) 内核态任务: 正在处理中断、异常、系统调用等, 此时 CPU 核心的执行优先级为 0, 最高优先级, 不可被抢占。3) 用户态任务: 正在执行用户态的任务, 此时 CPU 核心的执行优先级为当前线程的优先级, 可以被更高优先级线程提交的异步系统调用请求打断。

当发送端通过系统调用陷入内核去唤醒相应协程后, 会检查当前线程的优先级是否可以抢占其他 CPU 核心, 如果可以, 则发送核间中断抢占该 CPU 核心去执行异步系统调用, 当前 CPU 核心则返回用户态继续执行其他协程。如果没有可以被抢占的 CPU 核心, 则在下一次时钟中断到来时执行异步系统调用请求, 其伪代码如下:

算法: 唤醒内核中异步处理协程伪代码

```
fn wake_syscall_handler {
    current = get_current_thread;
    if let Some(cid) = current.async_sys_handler_cid {
        coroutine_wake(cid);
        current_exec_prio = current.tcb_prio;
        cpu_id, exec_prio = get_max_exec_prio();
        if (current_exec_prio < exec_prio) {
            // 抢占低执行优先级的核心
            mask = 1 << cpu_id;
            ipi_send_mask(mask, ASYNC_SYSCALL_HANDLE,
mask);
        }
    }
}
```

4 兼容性讨论

为了提升用户态程序的易用性, ReL4 对 seL4 的程序提供一定的兼容性。ReL4 中已经实现了 seL4 的基本系统调用并支持对称多处理机 (SMP), 但采用不同的通知机制和 IPC 设计, 因此有必要讨论这两部分的兼容性。

4.1 Notification 与 U-notification

相比于原始的通知机制, U-notification 在通信权限控制方面同主要存在以下两点不同: 1) 原始的通知机制允许多个接收线程竞争接收一个内核对象上的通知, 这种设计的目的是为了支持多接收端的场景, 事实上, 多接收端已经通过多个内核对象来进行支持, 因此这种机制相对冗余, 而由于 U-notification 中接收端对接收线程的独占性, 这个能力将不再被支持。2) 原始的通知机制允许单个接收线程接收多个内核对象上的通知, 这种设计的目的是更灵活地支持多发送端的场景, 在 U-notification 中, 同一个内核对象可以被设置为相同的 recv status idx, 不同的发送端则通过使用中断号

(uintr vec)来进行区分。

除了权限控制有所不同之外,改造前后的通信方式也有所区别。原始的通知机制需要用户态接收方通过系统调用主动询问内核是否有通知需要处理。根据是否要将线程阻塞,一般被设计为 Wait 和 Poll 两个接口。而 U-notification 无需接收线程主动陷入并询问内核,接收方被硬件发起的用户态中断打断,并处理到来的通知,这在很大程度上解放了接收方,程序设计者无需关心通知到来的时机,减少了 CPU 忙等的几率,提升了用户态的并发度。而为了提升 U-notification 的易用性,ReL4 对原始的通信接口进行了兼容:

1) Poll: 无需陷入内核态,在用户态读取中断状态寄存器,判断是否有效并返回。2) 对该接口的兼容需要用户态的异步运行时的调度器提供相关支持,在没有有效中断时,该操作将阻塞当前协程并切换到其他协程执行,等待用户态中断唤醒。

4.2 同步 IPC 与异步 IPC

异步 IPC 通过异步运行时可以在基本通信场景下上实现 API 级别的兼容,然而 seL4 中的同步 IPC 还有额外的能力:

- 1) 错误处理: 同步 IPC 可以用于缺页异常等处理, seL4 通过在 TCB 中维护一个 Endpoint 对象来发送错误信息给用户态程序进行处理,而在 ReL4 中,TCB 中将维护对应的 U-notification 对象,以及对应的共享缓冲区指针,当异常和错误发生时,将错误信息写入共享缓冲区,并发送 U-notification 通知用户态程序。此场景下依然可以实现 API 级别的兼容。
- 2) 能力派生: seL4 中的同步 IPC 拥有能力派生与传递的功能,虽然内核已经支持了 Capability Space 相关的系统调用,同步 IPC 使得能力传递更加灵活。而由于异步 IPC 不经过内核,因此 ReL4 中不再支持通过 IPC 来进行能力派生,仅通过系统调用进行能力派生,损失了一部分灵活性,保留了功能的完整性。

综上所述,异步 IPC 在大部分情况下依然能实现 API 级别的兼容。

5 评估

为了评估 ReL4 的兼容性,本文在 ReL4 上成功运行了 seL4test[28]并通过了相关的测试用例。而为了评估 ReL4 的性能表现,5.1 节设计了消融实验,来评估 U-notification 与自适应混合轮询对系统性能的影响;5.2 节通过内存分配器来评估异步系统调用的效率,5.3 节构建了 Ping-Pong 实验来评估异步 IPC 的性能;最后,5.4 节构建了一个真实的高并发的 TCP Server 程序用于评估 ReL4 在真实应用中的表

现。实验环境配置参数如表 4 所示。

表 4 实验环境参数

Table 4 Parameters of the experimental environment

环境	配置
FPGA	Zynq UltraScale + XCZU15EG-2FFVB1156
	MPSoC
	rocket-chip with N extension, 4 Core, 100MHz
	RISC-V 软 IP 核
	Xilinx AXI 1G/2.5G
	以太网 IP 核 Ethernet Subsystem (1Gbps)
操作系统	ReL4
网络协议栈	smoltcp

5.1 消融实验

本节设计了两个消融实验来评估 U-notification 和自适应混合轮询对性能的影响。第一个消融实验对比了 U-notification 与 notification 在多核下的性能差距(在单核下类似),如图 5 左侧子图所示,可以看出相比于原始的 notification 机制,U-notification 在软件上避免了页表切换和进程调度,减少了特权级切换的开销。而在硬件开销上,特别是在多核上,原始的通知机制通过核间中断唤醒接收进程,然而由于内核的独占性,需要等待发送核心退出内核之后接收核心才会处理中断,这导致了额外的进程调度延迟,造成多核心下的原始通知机制性能。两方面的优势使得 U-notification 在单核上性能提升 1x,在多核上性能提升 4x。

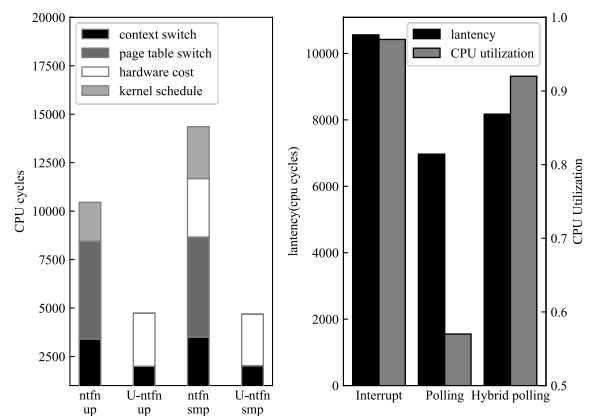


图 5 U-notification 与混合轮询的消融实验

Fig.5 Ablation Experiment of U-notification and Hybrid Polling

第二个消融实验通过对比中断、轮询、混合轮询对异步 IPC 延迟和 CPU 利用率来评估混合轮询的好处。实验设置

的客户端并发度为 16。实验结果图 5 右侧子图所示，全中断形式拥有良好的 CPU 利用率，但却有着较高的延迟，而轮询方式有较低的延迟，却同时会造成较低的 CPU 利用率，而混合轮询在二者之间进行了折中，并根据任务负载情况，自适应地调整中断频率。

5.2 内存分配服务器

为了验证异步系统调用对于系统性能的影响，本节在用户态设计了一个用于内存分配的服务器，该服务器线程通过消息队列不断接收其他线程发送的内存分配/释放请求，分别调用同步和异步的 map/unmap 系统调用处理请求并返回响应。结果图 6 所示，横坐标为服务器中的协程并发数，左侧纵坐标为单个系统调用的占用的平均 CPU 周期数，右侧纵坐标为系统调用陷入内核的频率，同步系统调用的频率为 1。




图 6 内存分配服务器性能测试

Fig.6 Performance Testing of Memory Allocator Server

从总体趋势上看，异步实现的内存分配器的性能随着并发度的提高，性能呈稳步上升的趋势，在并发度为 64 之后趋于稳定，这是由于并发度提升，内核陷入频率降低，特权级切换开销下降，导致了性能的提升。

同步和异步的对比来看，当并发度小于 32 时，同步系统调用的性能仍然高于异步系统调用，这是由于异步系统调用除了陷入内核的开销之外，还有运行时的开销以及 U-notification 的开销，因此在并发度较低时，减少的特权级切换开销少于增加的额外开销，因此异步系统调用性能较低。当并发度高于 32 后，特权级的切换开销急剧下降，因此异步的系统调用性能超过了同步 IPC，与异步 IPC 相似，当内核负载增加时，客户端陷入内核的频率也会逐渐下降，直至降为 0。

单核与多核对比来看，当内核与客户端不在同一个 CPU 核心上时，系统调用请求与处理将并行处理，因此性能会优于单核，但由于此时内核独占一个 CPU 核心，内核负载较小，客户端陷入内核的频率会略高于单核。

5.3 同步 IPC vs 异步 IPC

为了从微观角度评估异步 IPC 性能，本节测量了不同并发量和不同服务端负载下异步 IPC 和同步 IPC 的平均开销。由于本文关注的是同步 IPC 和异步 IPC 的路径差异，需要保证场景没有过多干扰，因此本节分别构建了一个服务端进程和一个客户端进程进行乒乓测试，测试结果如图 7 所示。




图 7 IPC 性能测试

Fig.7 Performance Testing of IPC

由于同步 IPC 会阻塞整个线程，因此并发量对同步 IPC 并没有意义。而在多核环境下，fast-path 检查会失败，所有的同步 IPC 都会在内核中通过核间中断进行传递，因此多核环境下的同步 IPC 性能很低；而对于单核下的同步 IPC，fast-path 会避开复杂的消息解码和冗长的调度流程，因此开启 fast-path 的 IPC 性能会提升 167%，但需要注意的是，fast-path 对于线程优先级、消息长度等有着严苛的检查流程，因此在实际应用场景中 fast-path 优化并不总能生效。

横向分析异步 IPC，可以发现异步 IPC 的开销随着并发量的提升而降低，这是由于随着并发量的增加，服务端的负载进一步增加，而 U-notification 的通知时机采用自适应的形式，因此通知频率下降，导致了均摊到每个 IPC 的开销下降。此外，在并发度较小的时候，多核会略快于单核（最高提升 52%），符合预期，随着并发度的逐渐增加，多核与单核的性能差异逐渐缩小（17%），这是由于多核情况下服务端单独使用一个 CPU 核心，导致服务端负载过小，产生了更加频繁的用户态中断，导致服务端吞吐量过小，又反过来限制了客户端的请求频率。

对比同步 IPC 和异步 IPC，当并发度为 1 的时候，每个异步 IPC 的开销都包含了两次用户态中断的开销、调度器的运行时开销，而同步 IPC 则是两次特权级切换的开销，如果没有 fast-path 优化，还会有内核路径中的解码开销和调度开销，因此在低并发度的场景下异步 IPC 的性能会略低于没有 fast-path 优化的同步 IPC（31%），同时显著低于有 fast-path 优化的同步 IPC（249%）。而当并发量较大时，用户态中断的频率减少，均摊到每一次 IPC 下，用户态中断的开销几乎可以忽略不计，因此异步 IPC 的开销主要是调度器的运行时

开销, 而此时的异步 IPC 性能会显著高于没有 fast-path 优化的同步 IPC (369%), 也高于有 fast-path 优化的同步 IPC (76%)。

上面的测试结果表明: 在多核场景下, 异步 IPC 相比于同步始终有着良好的表现。而在单核且低并发度场景下, 异步 IPC 性能会比较差, 但随着并发度增加, 异步 IPC 的性能会迅速提升, 在并发度为 2 时就已经超过没有 fast-path 优化的同步 IPC, 在并发度为 8 时就已经超过了开启 fast-path 优化的同步 IPC, 因此异步 IPC 依然十分有竞争力。

5.4 TCP 服务器

为了测试异步 IPC 在真实应用场景带来的收益, 本节在 ReL4 上实现了一个 TCP 服务器。模拟的 TCP 服务器应用场景由三部分组成, 一部分是运行在 PC 上的客户端, 它在启动时与运行在 FPGA 上的 TCP Server 建立若干个连接, 并不断地向服务端发送 64 字节 (小包) 的数据, 并接收服务器的响应; 第二部分是运行在 ReL4 上的网络协议栈服务器 (NW Stack Server), 集成了网卡驱动的代码, 并通过 smoltcp 协议栈维护每个连接的状态信息, 负责从网卡中接收数据并进行协议处理后通过共享缓冲区返回给 TCP Server, 以及从 TCP Server 接收数据并通过网卡发出; 第三部分是 TCP Server, 它以 IPC 的形式从 NW Stack Server 接收客户端发送过来的请求, 在处理完成之后返回响应并通过 NW Stack Server 发送给客户端。最后, PC 上的客户端计算发送每个请求和接收响应之间的时间延迟, 并计算固定时间段内的消息吞吐量。本节通过分析不同配置下 TCP Server 的时间延迟和吞吐量来评估 ReL4。需要注意的是, 由于同步 IPC 的无法支持多路复用, 因此同步 IPC 下每个连接都使用单独的线程来监听。测试结果如图 8 所示。

从总体趋势上看, 吞吐量随着并发度的增加呈现先增加后减少的趋势, 而时延成整体上升的趋势。在低并发度条件下的系统负载处于较低水平, 随着并发度增加, 吞吐量能稳步提升, 随着系统满载之后, 继续增加并发度, 会导致网络中断频率上升, 从而限制系统的整体性能, 吞吐量减少。

同步和异步对比来看, 可以看出当连接数较低, 并发度较小的情况下, 异步 IPC 实现的 TCP Server 无论是在吞吐量还是平均时延上都要优于同步 IPC, 这是由于同步 IPC 需要频繁陷入内核, 而由于微内核不可被抢占的设计, 内核态屏蔽了网络中断, 导致网络包无法及时处理。而随着并发度的增加, 由于同步 IPC 实现的 TCP Server 需要多线程来保证多连接, 因此线程切换的开销急剧加大, 导致同步和异步的差距进一步增加。在连接数为 4 的时候差距达到最大, 为 192%, 在并发度最大的情况下, 异步 IPC 实现的 TCP Server 也比同步 IPC 高出 120%。

单核与多核对比来看, 异步 IPC 实现的 TCP Server 随着 CPU 资源增加, 吞吐量提升, 时延降低, 而对于同步 IPC

实现的 TCP Server 情况则有所不同, 由于同步 IPC 在多核下采用的 IPI 的形式在内核进行转发, 导致程序的内存局部性和代码局部性都不够友好, 因此多核的性能表现会略低于单核。




图 8 TCP 服务器测试

Fig.8 TCP Server Test

上面的测试结果表明: 异步 IPC 在实际应用场景中有利于多路复用的实现, 可以有效减少特权级切换的开销, 提升系统的整体性能。

6 结束语

本文聚焦微内核的 IPC 机制, 提出一种高性能的异步微内核 ReL4, 将同步 IPC 从内核中移除, 仅支持异步的通知机制, 从而精简内核; 为了减少特权级切换, 提升系统性能, 利用用户态中断设计了 U-notification, 而为了提升用户态的易用性, 在用户态设计了异步运行时简化用户态编程模型。经测试, 异步 IPC 将 IPC 的性能提升了 3x, 在 IPC 频繁的系统 (如网络服务器) 将系统性能最高提升 1x。

本文提出的异步 IPC 和异步系统调用主要是为了提升高频度、上下文无关的 IPC 和系统调用请求的整体处理性能, 因此在并发度高的系统中拥有卓越的表现, 此外, 在并发度低的情况下, ReL4 仍然通过用户态中断这种开销相对较小的方式来取代特权级切换, 从而在一定程度上弥补了引入异步运行时带来的额外开销。然而从实验结果来看, 在并发度较低的场景下, 运行时开销仍然会导致性能略低于同步, 在未来的研究中, 可以用硬件实现异步运行时中的频繁操作 (如 fetch、wake 等), 从而尽可能消除运行时对性能的影响, 在低并发度的情况下也能取得良好的性能。

8 参考文献

- [1] Thallapally Abhilash. Microkernel vs Monolithic kernel Design Trade-offs [J]. International Journal For Multidisciplinary Research, 2024, 6(2): 1-5.
- [2] Liedtke J. Toward real microkernels[J]. Communications of the ACM, 1996, 39(9): 70-77.
- [3] Liedtke J. Improving IPC by kernel design[C]//Proceedings

of the fourteenth ACM symposium on Operating systems principles. 1993: 175-188.

[4] Klein G, Elphinstone K, Heiser G, et al. seL4: Formal verification of an OS kernel[C]//Proceedings of the ACM SIGOPS 22nd symposium on Operating systems principles. 2009: 207-220.

[5] Jeff Caruso. 1 million IOPS demonstrated [EB/OL]. <https://www.networkworld.com/article/2244085/1-million-iops-demonstrated.html>. Accessed: 2021-12-01.

[6] Lipp M, Schwarz M, Gruss D, et al. Meltdown: Reading kernel memory from user space[J]. *Communications of the ACM*, 2020, 63(6): 46-56.

[7] Kocher P, Horn J, Fogh A, et al. Spectre attacks: Exploiting speculative execution[J]. *Communications of the ACM*, 2020, 63(7): 93-101

[8] The kernel development community. Page table isolation(PTI) [EB/OL]. <https://www.kernel.org/doc/html/latest/x86/pti.html>. Accessed: 2021-12-01

[9] Blackham B, Shi Y, Heiser G. Improving interrupt response time in a verifiable protected microkernel[C]//Proceedings of the 7th ACM european conference on Computer Systems. 2012: 323-336.

[10] Heiser G, Elphinstone K. L4 microkernels: The lessons from 20 years of research and deployment[J]. *ACM Transactions on Computer Systems (TOCS)*, 2016, 34(1): 1-29

[11] Mi Z, Li D, Yang Z, et al. Skybridge: Fast and secure inter-process communication for microkernels[C]//Proceedings of the Fourteenth EuroSys Conference 2019: 1-15.

[12] Du D, Hua Z, Xia Y, et al. XPC: architectural support for secure and efficient cross process call[C]//Proceedings of the 46th International Symposium on Computer Architecture. 2019: 671-684.

[13] Kuo H C, Williams D, Koller R, et al. A linux in unikernel clothing[C]//Proceedings of the Fifteenth European Conference on Computer Systems. 2020: 1-15

[14] Olivier P, Chiba D, Lankes S, et al. A binary-compatible unikernel[C]//Proceedings of the 15th ACM SIGPLAN/SIGOPS International Conference on Virtual Execution Environments. 2019: 59-73.

[15] Yu K, Zhang C, Zhao Y. Web Service Appliance Based on Unikernel[C]//2017 IEEE 37th International Conference on Distributed Computing Systems Workshops (ICDCSW). IEEE, 2017: 280-282.

[16] Zhou Z, Bi Y, Wan J, et al. Userspace Bypass: Accelerating Syscall-intensive Applications[C]//17th USENIX Symposium on Operating Systems Design and Implementation (OSDI 23).

2023: 33-49.

[17] Jeong E Y, Wood S, Jamshed M, et al. mTCP: a Highly Scalable User-level TCP Stack for Multicore Systems[C]//11th USENIX Symposium on Networked Systems Design and Implementation (NSDI 14). 2014:489-502.

[18] Yang Z, Harris J R, Walker B, et al. SPDK: A development kit to build high performance storage applications[C]//2017 IEEE International Conference on Cloud Computing Technology and Science (CloudCom). IEEE, 2017: 154-161.

[19] Soares L, Stumm M. FlexSC: Flexible system call scheduling with Exception-Less system calls[C]//9th USENIX Symposium on Operating Systems Design and Implementation (OSDI 10). 2010.

[20] Nassif N, Munch A O, Molnar C L, et al. Sapphire rapids: The next-generation Intel Xeon scalable processor[C]//2022 IEEE International Solid-State Circuits Conference (ISSCC). IEEE, 2022: 44-46.

[21] The risc-v instruction set manual, volume ii: Privileged architecture, document version 1.12 [EB/OL]. <https://github.com/riscv/riscv-isa-manual/releases/download/draft20200212-c3d1f07/riscv-privileged.pdf>, 2020.

[22] Levy A, Andersen M P, Campbell B, et al. Ownership is theft: Experiences building an embedded OS in Rust[C]//Proceedings of the 8th Workshop on Programming Languages and Operating Systems. 2015: 21-26.

[23] Balasubramanian A, Baranowski M S, Burtsev A, et al. System programming in rust: Beyond safety[C]//Proceedings of the 16th workshop on hot topics in operating systems. 2017: 156-161.

[24] van Schaik C, Leslie B, Dannowski U, et al. NICTA L4-embedded kernel reference manual, version NICTA N1[R]. Technical report, National ICT Australia, October 2005.

[25] Heiser G, Leslie B. The OKL4 Microvisor: Convergence point of microkernels and hypervisors[C]//Proceedings of the first ACM asia-pacific workshop on Workshop on systems. 2010:19-24.

[26] Smejkal T, Lackorzynski A, Engel B, et al. Transactional ipc in fiasco. oc[J]. *OSPERS* 2015: 19-24.

[27] Rajwar R, Goodman J R. Transactional lock-free execution of lock-based programs[J]. *ACM SIGOPS Operating Systems Review*, 2002, 36(5): 5-17.

[28] General, N., & Data61. (n.d.). seL4test project. seL4 Documentation[EB/OL].

<https://docs.sel4.systems/projects/sel4test.2024>.